Appunti del corso di
Probabilità e Statistica

UniVR - Dipartimento di Informatica

secondo semestre - A.A. 2025/26

Mattia Nicolis Matteo Drago

Indice

1 Introduzione **1**
1.1 Raccolta dati e statistica descrittiva 1
1.2 Inferenza statistica e modelli probabilistici 2
1.3 Popolazioni e campioni 2

2 Distribuzioni di frequenze **4**
2.1 Distribuzine di frequenze: classi 4
2.1.1 Istogramma 5
2.1.2 Diagramma a barre 6
2.2 Frequenze cumulate e loro rappresentazione 7

3 Indici di posizione e dispersione **9**
3.1 Indici di posizione 9
3.1.1 Media 9
3.1.2 Mediana, quatrili e percentili 10
3.1.3 Moda 11
3.2 Indici di dispersione 12
3.2.1 Varianza e scarto quadratico medio 12
3.2.2 Indice di Gini 13
3.2.3 Entropia di Shannon 13

1

Introduzione

La **statistica** si occupa della raccolta dati, nella loro descrizione e analisi, guidandoci nel trarre le conclusioni.

1.1 Raccolta dati e statistica descrittiva

La statistica permette di descrivere, sintettizzare e analizzare dati presi da un campione di dati definito.
Altre volte, il lavoro dello statistico inizia prima che i dati siano stati ottenuti e il suo primo obiettivo consiste nell'ideare un procedimento ottimale per la loro raccolta.

Esempio: indagine statistica

Immaginiamo che un docente voglia determinare quale sia il più efficace tra due diversi metodi per insegnare la programmazione a dei neofiti.

Un possibile approcio potrebbe essere:

1. dividere gli studenti in due gruppi
2. usare un metodo didattico per ciascun gruppo

Alla fine del corso gli studenti vengono esaminati e i punteggi dei membri dei due gruppo vengono confrontati.
Se i risultati di uno dei due gruppi risultassarso notelvolemente più alti, sarebbe ragionevole pensare che il corrispondente metodo di insegnamento sia migliore.

È importante notare che per poter trarre delle conclusioni valide dei dati è essenziale che gli studenti siano divisi in modo che in nessuno dei due gruppi si vengano a trovare elementi con una maggiore predispozione alla programmazione.
Il metodo accettato per superare questo problema consiste nel dividere "a caso" gli studenti in due gruppi.

A esperimento concluso, i dati devono essere raccolti e commentati.

La parte della statistica che si occupa di illustrare e sintettizzare i dati è chiamata **statistica descrittiva**.

1.2 Inferenza statistica e modelli probabilistici

Considerando l'esempio fatto in precedenza, dopo che la prova si è conclusa e i dati sono stati illustrati e sintetizzati, vorremmo poter trarre una conclusione su quale dei due metodi di insegnamento sia superiore.

La parte della statistica che si occupa di questo aspetto è detta **inferenza statistica**.

Per dedurre enenunciati formalmemte validi dai dati raccolti, è necessario prendere in considerazione l'influenza del caso.

Esempio: indagine statistica

Potrebbe accadere che il punteggio medio dei membri del primo gruppo sia superiore, ma di poco, a quello del secondo gruppo.

È corretto concludere che questa differenza sia dovuta al metodo didattico utilizzato?

È possible che sia una casualità?

Per poter giungere a conclusioni pienamente giustificate è necessario fare alcune assunzioni sulla probabilità che i dati che vengono misurati assumano diversi valori possibili.
L'insieme di queste ipotesi è detto **modello probabilistico** per i dati.

A volte la natura dei dati suggerisce la forma del modello probabilistico da adottare.

Esempio: indagine statistica

Consideriamo un ingegnere della produzione che vuole scoprire la frazione di circuiti integrati difettosi riscontrata con un nuovo metodo produttivo.

Egli potrebbe selezionare un certo numero di chip e testarli: il numero di quelli difettosi costituirà il dato sperimentale.

Se la scelta del campione da testare è stata fatta "a caso" è ragionevole supporre che ciascuno dei chip sarà difettoso con probabilità p, pari alla frazione incognita di chip difettosi sul totale di quelli prodotti.

In altre situazioni potrebbe non essere evidente quale sia il modello di probabilità per un certo campione di dati.
Molto spesso, un'attenta descrizione e presentazione dei dati ci permette di inferire quale sia un modello accettabile, che può eventualmente essere messo alla prova raccogliendo nuovi dati.

1.3 Popolazioni e campioni

La statistica è normalmente interessata a ottenere informazioni su un insieme completo di oggetti che viene detto **popolazione**.
Esso, però, è spesso troppo grande perchè sia possibile un esame esaustivo.
In questi casi, si cerca di imparare qualcosa sulle popolazioni scegliendo e poi esaminnado dei

sottogruppi di loro elementi.
Un sottogruppo della popolazione è detto **campione**.
Siccome il campione deve contenere informazioni sulla popolazione complessiva, deve essere rapresentativo di quella popolazione.

Esempio: indagine statistica

Consideriamo di effettuare una ricerca sulla distribuzione delle età degli abitati di un certo comune e, intervistati i primi 100 che entrano in una biblioteca, venisse trovata che l'età media è di 46.2 anni.

Possiamo concludere che questa sia l'età media dell'intera popolazione?

Probabilmente no, perchè il campione scelto non è rappresentativo della popolazione in esame, essendo gli utenti della biblioteca più facilmente studenti e anziani che non persone in età lavorativa.

2

Distribuzioni di frequenze

La statistica riguarda i metodi scientifici per raccogliere, ordinare, riassumere e presentare i dati, per trarre valide conclusioni ed eventualmente prendere ragionevoli decisioni sulla base di tale analisi.

Definizione: variabili alleatorie

Le variabili oggetto di osservazione statistica si classificano in due tipologie:

- ▷ **varibili numeriche**: assume solo valori numerici $(\mathrm{N} = 0, 1, \ldots)$
  - ◇ discrete: insieme dei valori che può assumere è finito o numerabile
  - ◇ continue: insieme dei valori che può assumere è l'insieme dei numeri reali $\mathbb{R}$ o un intervallo $\mathrm{I} \subset \mathbb{R}$ $(\mathrm{H} \in \mathbb{R})$
- ▷ **variabili categoriche**: $\mathrm{C} = \mathrm{marrone}, \mathrm{blue}, \mathrm{verde}, \ldots$

I dati che non sono stati ancora ordinati numericamente si dicono **grezzi**.

Una **serie** è un ordinamento di dati grezzi in ordine crescente/decrescente.

La differenza tra il più grande e il più piccolo si dice **campo di variazione**.

2.1 Distribuzine di frequenze: classi

Per studiare i dati a disposizione occorre costruire una **distribuzione di frequenze**: una tabella dove in una colonna si mettono i valori assunti dalla variabile e in un'altra il numero delle volte che tali valori vengono assunti (frequenze).

Esempio: istrogramma

Consideriamo la varibile P peso di un gruppo di 100 studenti.

Peso in kg	Numero di studenti
$64 < P \leq 66$	5
$66 < P \leq 68$	18
$68 < P \leq 70$	42
$70 < P \leq 72$	42
$72 < P \leq 74$	8
Totale	**100**

Possiamo definire:

- ▷ **ampiezza** della classe: differenza tra il valore massimo e il valore minimo
- ▷ **valore centrale** della classe: semisomma degli estremi

Per rappresentare le distribuzioni di frequenze si utilizzano:

- ◇ **istogrammi**: variabili numeriche
- ◇ **diagrammi a barre**: variabili categoriche

2.1.1 Istogramma

Un **istogramma** consiste in un insieme di rettangoli adiacenti aventi base sull'asse x con:

- **punto medio** nel valore centrale della classe
- **altezza** proporzionale alla frequenza della classe
- **area** pari alla frequenza relativa/percentuale della classe

In questo modo se si sommano le aree di tutti i rettangoli ottenuti, si ottiene un valore fisso:

- ◇ 1: frequenze relative
- ◇ 100: frequenze percentuali

Esempio: diagramma a barre

Si consideri la seguente distribuzione di frequenze:

Distrubuzione	Frequenze
$110 < D \leq 130$	20
$130 < D \leq 150$	40
$150 < D \leq 170$	60
$170 < D \leq 210$	80
Totale	**200**

Riferendoci alla tabella in questione vogliamo determinare la frequenza percentuale e costruire il relativo istrogramma.

Distrubuzione	Frequenze	Frequenze %
$110 < D \leq 130$	20	10%
$130 < D \leq 150$	40	20%
$150 < D \leq 170$	60	30%
$170 < D \leq 210$	80	40%
Totale	**200**	**100%**

Riportiamo sull'asse x gli estremi delle classi.
Ricordando che l'area di ogni rettangolo deve dare le frequenze percentuali, si ha:

- ▷ **altezza prima classe**:
$$\frac{10}{(130-150)} = \mathbf{0.5}$$
- ▷ **altezza seconda classe**:
$$\frac{20}{(150-130)} = \mathbf{1.0}$$
- ▷ **altezza terza classe**:
$$\frac{30}{(170-150)} = \mathbf{1.5}$$
- ▷ **altezza quarta classe**:
$$\frac{40}{(210-170)} = \mathbf{1.0}$$

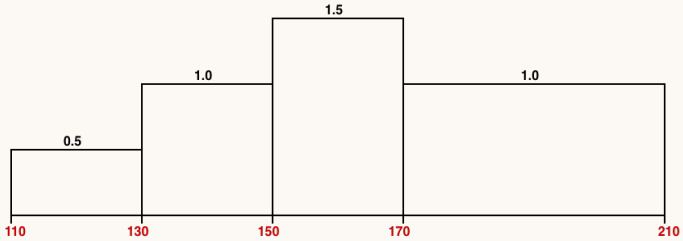

Figura 2.1: istogramma

2.1.2 Diagramma a barre

I **diagramma a barre** sono dei rettangoli, non allineati, in cui l'altezza rappresenta la frequenza relativa/percentuale di quella classe.
Sull'asse x si riportano i tipi, in un oridine deciso dall'osservatore stesso.

Esempio:

Consideriamo le frequenze dei colori degli occhi delle persone:

Colore occhi	Frequenze	Frequenze %
Marrone	150	50%
Blu	90	30%
Verde	30	10%
Altro	30	10%
Totale	**300**	**100%**

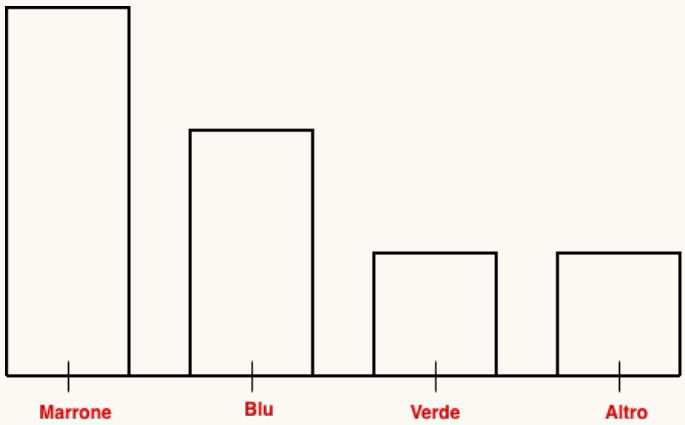

Figura 2.2: diagramma a barre

2.2 Frequenze cumulate e loro rappresentazione

La **frequenza cumulata** (variabili numeriche) è la somma di tutte le frequenza inferiori o uguali al confine di una fissata classe.
Per questo motivo le classi vengono prese aperte a sinistra e chiuse a destra.

Il grafico delle freuqenze cumulata è detto **ogiva**.

Esempio: calcolo delle frequenze cumulate

Consideriamo le seguenti distibuzioni di frequenza:

Distrubuzione	Frequenze
$110 < D \leq 130$	20
$130 < D \leq 150$	40
$150 < D \leq 170$	60
$170 < D \leq 210$	80
Totale	200

Riferendoci alla tabella in questione vogliamo determinare la frequenza percentuale cumulata e costruire il relativo grafico.

Distrubuzione	Frequenze	Frequenze %	Frequenze cumulate %
$110 < D \leq 130$	20	10%	10%
$130 < D \leq 150$	40	20%	30%
$150 < D \leq 170$	60	30%	60%
$170 < D \leq 210$	80	40%	100%
Totale	200	100%	

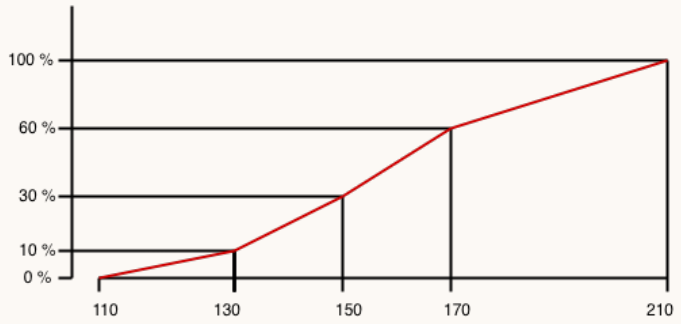

Figura 2.3: grafico a ogiva

3

Indici di posizione e dispersione

Al giorno d'oggi non è raro dover trattare grandi quantità di dati.
Per avere una sensazione di un così vasto campione di dati, è utile saperli sintettizzare in qualche misura

3.1 Indici di posizione

Gli **indici di posizione** aiutano a capire quali sono i valori che assume una certa distribuzione con particolare attenzione al centro di questa.

3.1.1 Media

Consideriamo di avere la seguente distribuzione: N rappresenta la numerisità della popolazione, n il numero delle classi.

X	Frequenze	Frequenze relative
x_1	f_1	p_1
x_2	f_2	p_2
$\vdots$	$\vdots$	$\vdots$
x_n	f_n	p_n
Totale	**N**	**1**

Definizione: media

Si chiama **media** di X è la quantità:

$$\bar{X} = \frac{1}{N}\sum_{i=1}^{n} x_i \cdot f_i = \sum_{i=1}^{n} xi \cdot p_i$$

Esempio: calcolo della media

Consideriamo la distribuzione di alcuni studenti.

Peso (Kg)	Frequenze	Frequenze relative
65	2	0.2
68	1	0.1
69	1	0.1
70	2	0.2
72	1	0.1
74	3	0.3
Totale	10	1.0

Si ha:

$$\bar{\mathbf{P}} = \frac{1}{10}(65 \cdot 2 + 68 \cdot 1 + 69 \cdot 1 + 70 \cdot 2 + 72 \cdot 1 + 74 \cdot 3) = \mathbf{70.1}$$

3.1.2 Mediana, quatrili e percentili

Definizione: mediana

La **mediana** è il valore che provoca la ripartione della popolazione in esame in due parti ugulamente numerose: per il 50% della popolazione il dato è minore della mediana, per il restante 50% il dato è maggiore della mediana.

Se abbiamo i dati non raggruppati, possiamo pensarli sotto forma di fila ordinata.
La mediana, allora, è:

- ▷ **valore centrale**: numeri dispari
- ▷ **media dei valori centrali**: numeri pari

Esempio: calcolo della mediana

Consideriamo il seguente campione X di numeri:

67, 72, 78, 78, 84, 85, 87, 91

Si tratta di un campione di numerosità 8 (pari):

$$\boldsymbol{Med(X)} = \frac{1}{2}(78 + 84) = 81$$

Consideriamo il seguente campione X di numeri:

65, 67, 72, 78, 78, 84, 85, 87, 91

Si tratta di un campione di numerosità 9 (dipari):

$$\boldsymbol{Med(X)} = 78$$

La media e la mediana sono statitsiche utili per descrivere i valori centrali dei dati.
La media fa uso di tutti i dati e, in particolare, è influenzata in maniera sensibile dai valori eccezionalmente alti o bassi.
La mediana, invece, dipende direttamente solo da uno o due valori in centro alla distribuzione e non risente dei dati estremi.

Definizione: quartili

I **quartili** sono quei valori che ripartiscono la popolazione (ordinata), in quattro parti ugulamente numerose (ciasuna pari al 25% del totale):

- ◇ **primo quartile** (q_1): 25% della popolazione a sinistra e il 75% a destra
- ◇ **secondo quartile** (q_2): 50% della popolazione a sinistra e il 50% a destra (mediana)
- ◇ **terzo quartile** (q_3): 75% della popolazione a sinistra e il 25% a destra

Se il campione si trova sotto forma di fila ordinata $(x_1, x_2, \ldots, x_N)$, allora per il calcolo si procede in modo analogo a quanto fatto per la mediana.
Se si vuole calcolare q_k si moltiplica $p = 0.k$ per la numerosità del campione N:

- se pN è intero:

$$q_k = \frac{1}{2}(x_{pN} + x_{pN+1})$$

- se pN non è un numero intero:

$$q_k = x_{\lfloor pN \rfloor + 1}$$

Esempio: calcolo dell'n-simo quartile

Consideriamo il seguente campione X di numeri:

67, 72, 78, 78, 84, 85, 87, 91

Si tratta di un campione di numerosità 8 (pari).
Quanto valgono i quartili?

- ▷ **primo quartile**: $0.25 \cdot 8 = 2$

$$q_1 = \frac{1}{2}(x_2 + x_3) = \frac{1}{2}(72 + 78) = \mathbf{75}$$

- ▷ **secondo quatrile**:

$$q_2 = \mathrm{Med}(X) = \frac{1}{2}(78 + 84) = \mathbf{81}$$

- ▷ **terzo quatrile**: $0.75 \cdot 8 = 6$

$$q_3 = \frac{1}{2}(x_6 + x_7) = \frac{1}{2}(85 + 87) = \mathbf{86}$$

3.1.3 Moda

Definizione: moda

La **moda** di un insieme di dati, se esiste, è l'unico valore che ha la freuqunza massima.
Se non vi è solo valore con frequenza massima, ciascuno di essi è detto **valore modale**.

Perchè sccegliere la moda, invece, di media o mediana?

La moda identifica il picco della distribuzione (scelta prevalente), mentre la media può rappresentare un valore che non è mai stato osservato.

3.2 Indici di dispersione

Gli **indici di disperisione** indicano quanto i dati sono concetrati o viceversa dispersi attorno a tali valori tipici.

3.2.1 Varianza e scarto quadratico medio

È interessante misurare, quindi, il grado di disperisione dei dati rispetto, ad esempio, alla media.
Si osserva che la somma di tutte le derivazioni dalla media è sempre zero:

$$\sum_{i=1}^{n}(x_i - \bar{X}) \cdot f_i = 0$$

Perciò, per misurare in modo significativo la disperisione dei dati rispetto alla media, si può considerare, ad esempio, la somma dei moduli delle derivazioni, oppure la somma dei quadrati delle derivazioni.

Consideriamo di avere la seguente distribuzione: N rappresenta la numerisità della popolazione.

X	Frequenze	Frequenze relative
x_1	f_1	p_1
x_2	f_2	p_2
$\vdots$	$\vdots$	$\vdots$
x_n	f_n	p_n
Totale	**N**	**1**

Definizione: varianza

Si chiama **varianza** di X la media degli scarti al quadrato:

$$s_X^2 = \frac{1}{N}\sum_{i=1}^{n}(x_i - \bar{X})^2 \cdot f_i = \sum_{i=1}^{n}(x_i - \bar{X})^2 \cdot p_i$$

Definizione: scarto quadratico medio

Si chiama **scarto quadratico medio** o **deviazione standard** di X la radice della varianza:

$$s_X = \sqrt{\frac{1}{N}\sum_{i=1}^{n}(x_i - \bar{X})^2 \cdot f_i} = \sqrt{\sum_{i=1}^{n}(x_i - \bar{X})^2 \cdot p_i}$$

La varianza e la deviazione standard sono grandezze non negative che si annullano solo quanto gli x_i, sono tutti uguali tra loro e, quindi, uguali alla loro media.

Il calcolo della varianza può essere semplificato se si nota che, prese comunque due costanti a e b, se si considera il nuovo insieme di dati $y_i := ax_i + b$, dove $i = 1, 2, \ldots, n$, allora per quanto già detto $\bar{Y} = a\bar{X} + b$ e, quindi:

$$\sum_{i=1}^{n}(y_i - \bar{Y})^2 = a^2 \sum_{i=1}^{n}(x_i - \bar{X})^2$$

Perciò, se s_y^2 e s_x^2 sono le rispettive varianza campionarie, si ha che:

$$s_y^2 = a^2 s_x^2$$

Esempio: calcolo della varianza e deviazione standard

Consideriamo la seguente distribuzione di frequenze:

Distrubuzione	Frequenze
$110 < D \leq 130$	20
$130 < D \leq 150$	40
$150 < D \leq 170$	60
$170 < D \leq 210$	80
Totoale	200

La media è uguale a:

$$\bar{D} = \frac{1}{200}(120 \cdot 20 + 140 \cdot 40 + 160 \cdot 60 + 190 \cdot 80) = \mathbf{164}$$

Distrubuzione	$(D - \bar{D})^2$	D^2	Frequenze
$110 < D \leq 130$	$(120 - 164)^2$	120^2	20
$130 < D \leq 150$	$(140 - 164)^2$	140^2	40
$150 < D \leq 170$	$(160 - 164)^2$	160^2	60
$170 < D \leq 210$	$(190 - 164)^2$	190^2	80
Totoale			200

La varianza è uguale a:

$$s_D^2 = \frac{1}{200}[(120-164)^2 \cdot 20 + (140-164)^2 \cdot 40 + (160-164)^2 \cdot 60 + (190-164)^2 \cdot 80] = \mathbf{584}$$

Lo scarto quadratico medio è uguale a:

$$s_D = \sqrt{s_D^2} = \mathbf{24.17}$$

3.2.2 Indice di Gini

3.2.3 Entropia di Shannon